



מדע נתונים תאוריה ומעשה
50058
יום ב', 16:00-20:00
סמסטר קיץ תשפ"ו, 2025/2026
עבודת בית 1

מגיש : עידו וינשטוק 211677083
מרצה : ד"ר אורי איתי
מתרגלת : חנית חדד אוחיון
בודק : דרור מאירוביץ'



תוכן עניינים

3	סעיף 2 – בחירת מערך נתונים.....
3	תת סעיף 1 – דרישות.....
3	תת סעיף 2 – תיאור מקור הנתונים.....
4	סעיף 3 – מטא אנליזה של הנתונים.....
4	תת סעיף 1 – ניתוח הקובץ.....
4	תת סעיף 2 – מבנה הנתונים.....
7	סעיף 4 – איכות והשלמת נתונים.....
7	תת סעיף 1 – נתונים חסרים.....
8	תת סעיף 2 – כפילויות.....
9	תת סעיף 3 – ערכים חשודים.....
10	תת סעיף 4 – קרדינליות.....
11	סעיף 5 – ניתוח חד משתני.....
11	תת סעיף 1 – משתנים מספריים.....
20	תת סעיף 2 – משתנים קטגוריאליים.....
31	סעיף 6 – קורלציה וקשרים.....
31	תת סעיף 1 – קטגוריות מספריות.....
35	תת סעיף 2 – משתנים קטגוריאליים.....
38	סעיף 7 – ניתוח האינדקס.....
39	סעיף 8 – תובנות וסיפור הנתונים.....
40	סעיף 9 – בונוס.....
41	דגשי למידה.....



סעיף 2 – בחירת מערך נתונים

תת סעיף 1 – דרישות

כמות שורות - 5500

כמות עמודות - 18

סוגי משתנים –

במאגר הנתונים קיימים נתונים מספריים, משתני זמן (שנים) ומשתנים קטגוריאליים.

תת סעיף 2 – תיאור מקור הנתונים

מקור הנתונים –

ה – dataset הנבחר הינו "automobile_dataset.csv".
מאגר נתונים זה נבחר מתוך אתר Kaggle בקישור המצורף.

מטרת האיסוף –

מטרת איסוף הנתונים במסד זה היא לאפשר ניתוח, ויזואליזציה ובניית מודלים של למידת מכונה כדי לחקור את שוק הרכבים המשומשים ולחזות את מחירי המכירה שלהם. הנתונים נאספו כדי לבחון כיצד מאפיינים שונים כגון שנת ייצור, קילומטראז' (מרחק שהרכב נסע, במקרה שלנו ביח' מייל), נפח מנוע, סוג דלק, סוג תיבת הילוכים ומצבו הכללי של הרכב משפיעים על ערך השוק שלו, ובכך לספק תשתית עשירה להנדסת מאפיינים ולפיתוח מודלים חזויים (כמו רגרסיה). מעבר לכך, המאגר נועד לשמש כלי עבודה שימושי הן למתחילים והן לאנשי מקצוע בתחום ה – data science לצורך ביצוע ניתוח נתונים ראשוני (EDA), הפקת ויזואליזציות ומחקר שוק בענף הרכב (ע"פ תיאור הגורם האוסף).

הגורם האוסף –

Rana Ghulam Nabi

סטודנט פקיסטני למדעי הנתונים אשר מפרסם באופן פעיל מאגרי נתונים ב플טפורמת Kaggle. מאחר ואיננו גורם ידע רשמי או מוסמך למחקר אקדמי / עסקי, מאגרי הנתונים שלו טובים לתרגול טכניקות בהנדסת נתונים, ללמידה ולפיתוח פרויקטים אישיים, אך יש לקחת את התוצאות והמסקנות העולות מן הנתונים בערבון מוגבל.



סעיף 3 – מטא אנליזה של הנתונים

תת סעיף 1 – ניתוח הקובץ

גודל הקובץ -

בזכרון המהיר (RAM) - 1.0 MB (ע"פ פקודת info).
בדיסק הקשיח - 549.7KB (ע"פ עמוד מאגר הנתונים בקגל).

הסיבה להבדל בין הנתונים הוא שבעת פתיחת ה - dataset באמצעות ספריית pandas הטבלה משנה פורמט ע"מ שתתאים לצריבה ב RAM ע"מ שיוכלו להתבצע עליה חישובים מהירים.

פורמט - CSV

תאריך יצירה - 16.7.2026

תת סעיף 2 – מבנה הנתונים

מס' שורות ועמודות -

שורות - 5500
עמודות - 18

שמות העמודות -

1. יצרן
2. דגם
3. שנת ייצור
4. סוג דלק
5. סוג תמסורת
6. גודל מנוע
7. מרחק שהרכב נסע
8. כח סוס
9. טורק
10. יד (כמות בעלים קודמים)
11. הסטוריית תאונות
12. הסטוריית טיפולים
13. צבע
14. סוג גוף
15. הנעה (קדמית, אחורית, 4X4)
16. צריכת דלק
17. מיקום
18. מחיר מכירה



האם שמות עמודות אלו עושים הגיון?

שמות העמודות מייצרות תמונה כוללת עבור כל רכב במגוון רחב של היבטים המאפשרת בחינה מעמיקה באופן פרטני ורוחבי אל מול רכבים אחרים.

מה אפשר ללמוד משמות העמודות?

ניתן ללמוד משמות העמודות על

סוגי נתונים וסוג הטיפוס שלהם

אינדקס	שם העמודה	סוג הטיפוס	סוג הנתון
1	יצרן	Str	קטגוריאלי
2	דגם	Str	קטגוריאלי
3	שנת ייצור	Int	זמן
4	סוג דלק	Str	קטגוריאלי
5	סוג תמסורת	Str	קטגוריאלי
6	גודל מנוע	Float	נומרי
7	מרחק שהרכב נסע	Int	נומרי
8	כח סוס	Float	נומרי
9	טורק / מומנט	Float	נומרי
10	יד	Int	נומרי
11	הסטוריית תאונות	Float	נומרי
12	הסטוריית טיפולים	Str	קטגוריאלי
13	צבע	Str	קטגוריאלי
14	סוג הגוף	Str	קטגוריאלי
15	הנעה	Str	קטגוריאלי
16	צריכת דלק	Float	נומרי
17	מיקום	Str	קטגוריאלי
18	מחיר המכירה	Int	נומרי

מה ניתן ללמוד מסוג הטיפוסים?

ערכים נומריים – מייצגים ערכים מדידים או ספירים בנוגע לכל רכב. ניתן לבצע על משתנים אלו חישובים סטטיסטיים ישירים (ממוצע, חציון וכו').

ערכים קטגוריאלים – מייצגים תכונות של כל אובייקט. ע"מ לבצע ניתוח סטטיסטי שלהם יהיה עלינו לקודד אותם קודם.

ערכי זמן – משתנה הזמן מייצג את שנת ייצור הרכב כ – int. ע"מ לבצע ניתוח סטטיסטי מעמיק כדאי להעביר את משתנה זה למשתנה מסוג day time. כלומר לחסר מן התאריך הנוכחי את שנת הייצור ע"מ לגלות מהו גיל הרכב.



האם נתונים אלו נאספו לצורך מחקר או תפעול?

אני משער שמאגר הנתונים נאסף באמצעות מאגר תפעולי מתוך לוח מכירות רכבים של סוכנויות רכבים / חברות ביטוח / אתרי מכירת רכב וכו'.
הנתונים נאספו כנראה כחלק מפעילות עסקית שוטפת של רישום רכב למכירה ותיעוד מצבו.

אילו הטיות עשויות להופיע?

- מוכרים נוטים להשמיט או לדווח בצורה חלקית/סובייקטיבית על עמודות כמו היסטוריית תאונות או היסטוריית טיפולים. לא ניתן לדעת אם הנתונים בטבלה מאומתים.
- עמודת מחיר המכירה מייצגת לרוב את המחיר שהמוכר דרש במודעה ולא את המחיר הסופי שבו הרכב נמכר בפועל (ירידת מכיר לאחר מיקוח, בדיקת רכב במוסך וכו').
- הנתונים נאספו מאזור גיאוגרפי או מלוח מכירות מסוים אינם מייצגים את שוק הרכב העולמי.
- אנומליות:
רכבי אספנות – רכבים ישנים, מחירים גבוהים. לא לסווג כאנומליה.
רכבים שעברו תאונות קשות – חלקם חדשים במחירים זולים. לא לסווג כאנומליה.
טעויות הקלדה אנושיות.



סעיף 4 – איכות והשלמת נתונים

תת סעיף 1 – נתונים חסרים

היקף החוסר

אינדקס	שם העמודה	סוג הטיפוס	כמות חוסרים
1	יצרן	Str	0
2	דגם	Str	0
3	שנת ייצור	Int	0
4	סוג דלק	Str	0
5	סוג תמסורת	Str	827
6	גודל מנוע	Float	844
7	מרחק שהרכב נסע	Int	0
8	כח סוס	Float	800
9	טורק / מומנט	Float	799
10	יד	Int	0
11	הסטוריית תאונות	Float	812
12	הסטוריית טיפולים	Str	855
13	צבע	Str	803
14	סוג הגוף	Str	0
15	הנעה	Str	0
16	צריכת דלק	Float	794
17	מיקום	Str	782
18	מחיר המכירה	Int	0

דפוס (אקראי / מובנה)

ניתן להבחין שכמות החוסרים נעה בין 782 ל – 855 ערכים, כלומר קיימת שונות נמוכה. לכן ניתן לקבוע כי בסבירות גבוהה היה קיים כשל בעת הליך איסוף הנתונים, לדוגמא:

- שדות שהמוכרים לא היו חייבים למלא
- תהליך חילות מידע מאתר WEB שכשל (web scrapping) באופן עקבי בחילוף שדות מסויימים.
- רכב חשמלי שאין לו מנוע תמסורת, צריכת דלק וכו'.

מה ניתן להסיק מחוסרי הנתונים?

- איכות web scrapping ירודה.
- ניסיון של המוכרים לייצר הטיה סלקטיבית ע"י הזנת הפרמטרים החיוביים בפרט ולא השליליים (השדות שלא מולאו).



איך הייתי משלים את הנתונים החסרים?

משתנים נומריים (גודל מנוע, כ"ס, מומנט וצריכת דלק) :

- קיבוץ של המידע הידוע על אותו סוג הרכב (יצרן, דגם, שנת ייצור) ומילוי ע"פ ממוצע / חציון / שכיח.
- יצירת טבלת חוסרים ומילוייה מהאינטרנט. חיפוש בגוגל של השכיח ביותר באותה קטגוריה (במידה ויש כ"א זמין למשימה).
- יצירת טבלת חוסרים ומילוייה באמצעות מודלי שפה גדולים. מודלים מסוג זה מאומנים על כמות פרמטרים גדולה מאוד וקיים סיכוי סביר שע"י chunking יוכלו להפיק תשובות בעלות ערך. יש להשיג הרשאת API למודל שפה גדול במידה וקיים כזה מטעם העבודה או במקרה של עבודה פרטית למודל חינמי כמו GPT OSS.

משתנים קטגוריאליים (סוג תמסורת, הסטוריית תאונות, טיפולים, צבע ומיקום) :

- הגדרת קטגוריה חדשה – missing. הדבר יאפשר לנו בהמשך להסיק על השפעת חוסר הדיווח.

תת סעיף 2 – כפילויות

כפילויות מלאות

במסגרת שלב ניקוי ותיקוף הנתונים, בוצעה בדיקה לזיהוי כפילויות מלאות על פני כלל המשתנים במאגר. תוצאות הבדיקה הראו כי לא קיימות רשומות זהות לחלוטין (0 מופעים כפולים), מה שמעיד על כך שלא אירעו שגיאות של הזנה כפולה או שכפול רשומות בעת יצירת ואיחוד הקבצים.

כפילויות חלקיות

בנתוני לוחות רכב לעיתים קרובות מוכר מעלה את אותה מודעה פעמיים במועדים שונים, או מעדכן קלות את המחיר – מה שמשנה עמודה אחת או שתיים, אך בפועל מדובר באותו הרכב בדיוק. כדי לוודא שאין כפילויות חלקיות אבחן כמה שורות כפולות יש בהינתן x עמודות שונות, וכך אחלץ מהם המשתנים אשר מהווים את גורם ההבדל המשמעותי ביותר בין רכב לרכב.

לאחר בניית לולאה מצאתי שהפרמטרים המבדילים ביותר בין אובייקט לאובייקט (ע"פ סדר) הינם :

1. גודל המנוע
2. סוג הדלק
3. שנה
4. גיר
5. קילומטראז'
6. דגם
7. כ"ס

ניתן גם כניתוח עתידי לבחון את השפעת זוגות משתנים על כפילויות.

מה ניתן להסיק מן הכפילויות

הגורם המבדיל המשמעותי ביותר בהבדלה בין גרסאות שונות של רכבים הוא סוג המנוע. לולא פרמטר זה רוב גרסאות הרכב היו זהות. הסרתו הובילה לזינוק של 2580 כפילויות, משמעותי פי כמה או בסדרי גודל מהפרמטרים האחרים.



תת סעיף 3 – ערכים חשודים

במסגרת ניתוח איכות הנתונים הופעה של ערכים חריגים, אפסים או placeholders אינם מהווים שגיאה, אלא מידע בנוגע למאגר הנתונים (לדוגמא יכול להיות שרכב חשמלי תוייג כבעל גודל מנוע שלילי. כמובן שזו תוצאה שאינה אפשרית שמלמדת על סוג הרכב. דוגמא זו אינה נכונה במאגר הנתונים הקיים).

אאתר ערכים אלו ע"י מציאת הערכים המקסימליים והמינימליים במאגר הנתונים.

ערכים בלתי סבירים

מניתוח data frame של הרכבים החשמליים בלבד אני מזהה מס' תופעות בלתי סבירות:

- מודלים של רכבים חשמליים שהושקו בשנים לא הגיוניות.
- מודלים של רכבים שמעולם לא יצאו לקהל הרחב בגרסה חשמלית.

לדוגמא: הונדה אקורד מודל 2015 חשמלית. רכב שקיים אך ורק בגרסת בנזין או דיזל ומעולם לא שווק בגרסה חשמלית, בטח ובטח שלא בשנת 2015. וידאתי זאת באמצעות חיפוש ברחבי האינטרנט באתר החברה, אתר מכירות רחבים בארה"ב יד שנייה ועוד.

- צריכת דלק של רכב חשמלי.
- רכבים שנמכרים במחיר זול מאוד – לאחר בדיקה מדובר ברכבים ישנים מאוד.
- רכבים בעלי מרחק נסיעה נמוך מאוד – מדובר ברכבים חדישים במחירים גבוהים.

Values placeholder

על סמך טבלת ערכים מקסימליים ומינימליים מצאתי כי משתנה אחד בו יש ערכים בלתי אפשריים – גודל המנוע. בונה מאגר המידע תייג רכבים חשמליים כבעלי מנוע בגודל – 0.

מתוך data frame זה חיפשתי רכבים שגודל המנוע שלהם שונה מאפס ולא מצאתי. כלומר – כל רכב חשמלי תוייג כבעל גודל מנוע אפס.

האם אותם ערכים מספרים לנו משהו על המידע

- צריכת דלק של רכב חשמלי - מספר לנו על אחת משתי אפשרויות:
 - א. אוסף המידע ביצע את עבודתו ברשלנות ומאגר המידע אינו אמין.
 - ב. מדובר בצריכת חשמל.

השערה – אפשרות א' הינה הנכונה, מאחר ובנוגע לרכבים היברידיים אוסף המידע שם אפשרות אחת בלבד (לא דלק וחשמל יחד).


- רכבים בעלי גודל מנוע אפס מתוייגים כרכבים חשמליים בהכרח.



תת סעיף 4 – קרדינליות

ערכי מאגר הנתונים מתאפיינים במגוון רחב של קרדינליות. רוב הערכים או בעלי קרדינליות נמוכה מאוד או בעלי קרדינליות גבוהה מאוד.

ה – bar chart המצורף ממחיש את כמות האפשרויות עבור כל אחד מהמשתנים.





סעיף 5 – ניתוח חד משתני

תת סעיף 1 – משתנים מספריים

שם המשתנה	סוג הטיפוס	ממוצע	סטיית תקן	שונות	מקס'	מינ'	Skewness מומנט מסדר 3	Kurtosis מומנט מסדר 4
שנת ייצור	Int	2014.5	5.789	33.52	2024	2005	0.01	-1.2
גודל מנוע	Float	2.45	0.84	0.712	5.7	0	0.32	2.36
מרחק שהרכב נסע	Int	114529.4	91858.9	$8 \cdot 10^9$	536731	100.0	0.837502	0.225634
כח סוס	Float	198.2	55.6	$3.1 \cdot 10^3$	434	97	1.1	1.68
טורק / מומנט	Float	189.014678	56.631309	$3.2 \cdot 10^3$	443.0	77.0	1.204792	2.045085
יד	Int	2.464000	1.280022	1.638	5.0	1.0	0.368718	-1.01937
הסטורית תאונות	Float	0.408063	0.491527	0.24	1.0	0.0	0.374246	-1.8607
צריכת דלק	Float	34.179771	15.085473	227.57	141.0	10.0	3.687088	17.38362
מחיר המכירה	Int	12319.87	12658	$1.6 \cdot 10^8$	86692.0	500.0	1.336798	1.701317

שם המשתנה	סוג הטיפוס	חציון	MAD	Q1	Q3	IQR
שנת ייצור	Int	2014	5	2009	2020	11
גודל מנוע	Float	2.4	0.5	2	3	1
מרחק שהרכב נסע	Int	96926.5	64859.5	39112.00	172757.5	133645.50
כח סוס	Float	187	34	160	231	71
טורק / מומנט	Float	178.0	34.0	151.00	219.0	68.00
יד	Int	2.0	1.0	1.00	3.0	2.00
הסטורית תאונות	Float	0.0	0.0	0.00	1.0	1.00
צריכת דלק	Float	32.0	5.0	27.00	37.0	10.00
מחיר המכירה	Int	8586.0	8086.0	1304.75	19097.5	17792.75



התפלגות

ע"מ לקבוע את סוגי ההתפלגויות איעזר ב - 2 כלים:

- מומנטים סטטיסטיים.
- גרפים. במקרה שלנו ניעזר בהיסטוגרמה.

ניתוח ע"פ מומנטים

מומנט מסדר 3 – skewness

ערך גבוה מעיד על התפלגות א-סימטרית ימנית.

ערך קרוב לאפס מעיד על התפלגות שווה בין 2 צדדי המרכז.

ערך שלילי מעיד על התפלגות א-סימטרית שמאלית.

מומנט מסדר 4 – kurtosis

מומנט זה מתאר את כובד הזנבות.

ערך חיובי מתאר התפלגות דמויית פונק' הלס.



ערך קרוב לאפס מתאר התפלגות קרובה להתפלגות נורמלית.



ערב שלילי מאוד מתאר התפלגות אחידה.







ניתוח ע"פ היסטוגרמה


ניעזר בהיסטוגרמה ע"מ לאשש את ההנחות שצינתי בנוגע לתובנות בנוגע למומנטים על התפלגות הדאטה.














מאחר ולכל אחד מהמשתנים הנומריים ישנם המון ערכים אפשריים ארגון המידע בדיאגרמת box plot אינה נותנת ערך מוסף:





מציאת ערכים חריגים

למדנו בכיתה 3 שיטות למציאת ערכים חריגים:

1. באמצעות IQR נגדיר 2 גבולות גזרה כאשר ערכים מעל ומתחת יהוו ערכים חריגים. הגבולות הינם:

$$\text{Lower bound} = Q_1 - 1.5 \cdot IQR$$

$$\text{Upper bound} = Q_3 + 1.5 \cdot IQR$$

2. 3 סטיות תקן מהממוצע

$$|x - \mu| > 3 \cdot \sigma$$

3. 3 MAD מהחציון:

$$|x - \text{Median}| > 3 \cdot MAD$$

נבצע את כל אחת מהשיטות על הדאטה ע"מ לתפוס ערכים חריגים. בטבלה מדדתי את כמות הערכים החריגים שנמצאו בכל אחת מן השיטות.

שיטה I IQR	שיטה II באמצעות 3 סטיות תקן מהממוצע	שיטה 3 באמצעות 3 MAD מהחציון	שם המשתנה
0	0	0	שנת ייצור
239	63	328	גודל מנוע
54	30	261	מרחק שהרכב נסע
144	82	289	כח סוס
187	88	301	טורק / מומנט
0	0	0	יד
0	0	1913	הסטוריית תאונות
274	128	433	צריכת דלק
144	82	426	מחיר המכירה



תת סעיף 2 – משתנים קטגוריאליים

שכיחות מתארת את המשתנה שהופיע הכי הרבה פעמים באותה הקטגוריה. נבדוק מהי האפשרות השכיחה ביותר עבור כל אחד מן המשתנים הקטגוריאליים ואיזה אחוז מהדאטה הוא תופס.

האחוזים מתייחסים לסך התאים בעמודה (5,500) ולא לסך התאים המלאים בערך "לא ידוע".

שם המשתנה	השכיח ביותר	כמות חזרות	אחוז נפח מבין האפשרויות (%)
יצרן	יונדאי	579	10.53
דגם	GLE	166	3.02
סוג הדלק	בנזין	4267	77.58
תיבת הילוכים	אוטומטי	4142	75.31
הסטוריית טיפולים	טיפול מלא	1877	34.13
צבע	לא ידוע	803	14.60
סוג הגוף	SUV	2703	49.15
הנעה	FWD	2568	46.69
מיקום	לא ידוע	782	14.22



אחפש את 3 הערכים השכיחים ביותר עבור כל קטגוריה ($k = 3$). הערכים מסודרים לפי שכיחות.

שם המשתנה	אחוז כיסוי (%)	הערכים המובילים
יצרן	31.4	יונדאי פורד וולקסווגן
דגם	8.82	GLR אלנטרה פאסאט
סוג הדלק	77.58	בנזין דיזל היברידי
תיבת הילוכים	100	אוטומט לא ידוע ידני
הסטוריית טיפולים	84.45	טיפולים מלאים טיפולים חלקיים ללא טיפול
צבע	94.95	לא ידוע חום שחור
סוג הגוף	89.87	SUV סדאן משאית
הנעה	95.93	FWD AWD RWD
מיקום	32.71	לא ידוע GA CA



אחפש את K האפשרויות המינימלי המהווה לפחות 50 אחוז מהמידע עבור אותו משתנה.

שם המשתנה	K	אחוז כיסוי (%)	הערכים המובילים
יצרן	5	51.56	יונדאי פורד וולקסווגן שברולט הונדה
דגם	19	51.40	GLR אלנטרה פאסאט סיוויק מאליבו אקספלורר
סוג הדלק	1	77.58	בנוזן
תיבת הילוכים	1	75.31	אוטומט
הסטוריית טיפולים	2	67.95	טיפולים מלאים טיפולים חלקיים
צבע	5	58.71	לא ידוע חום שחור אדום ירוק
סוג הגוף	2	89.87	SUV סדאן
הנעה	2	89.76	FWD AWD
מיקום	5	50.47	לא ידוע GA CA PA NY

הערכים המרכזיים מספקים לנו מידע על ההיצע באחד מאתרי מכירות הרכבים בארה"ב.

מאחר ובאופן טבעי קיימים יותר אנשים פרטיים מאשר עסקים העוסקים בהובלה כבדה, אנשי עסקים או מקצועות ספציפיים, ניתן להבחין כי הקטגוריות השכיחות ביותר מספקות אינפורמציה על הרכבים המיועדים לאנשים פרטיים בלבד. רכבים אלו מכונים בהגה המקצועית הישראלית – "פרייבטים".



אחפש את 3 הערכים הנדירים ביותר (הכי פחות שכיחים) בכל קטגוריה. הערכים מסודרים ע"פ נדירות.

שם המשתנה	הערכים הנדירים
יצרן	BMW אאודי טויוטה
דגם	C-Class Q5 X3
סוג הדלק	חשמלי היברידי דיזל
תיבת הילוכים	ידני לא ידוע אוטומטי
הסטוריית טיפולים	לא ידוע ללא טיפול טיפול חלקי
צבע	לבן כסוף אפור
סוג הגוף	האצ'בק קופה משאית
הנעה	4WD RWD AWD
מיקום	FL MI NC



לא ניתן להתעלם מקטגוריות אלו מאחר והן מספקות תובנות חשובות. לדוגמא:



- יש פחות היצע של רכבי ספורט (מבנה = קופה) או משאיות למכירה. ככל הנראה מעיד כך שרוב האוכלוסיה אינה אמידה. מתאים להתפלגות נורמלית של אוכלוסיה.
- רכבים חשמליים בארה"ב נמכרים פחות מאשר מכוניות מסורתיות (דזל, בנזין וכו'). הגיוני ומלמד על הרגלי הצריכה של אמריקנים ועל הרגלי הנסיעה שלהם – נסיעות לטווחים ארוכים (דבר שאינו מתאפשר ברכבים חשמליים).
- יש היצע נמוך של רכבים בעלי גיר ידני. מעיד על הרגלי הנהיגה של האמריקנים. בד"כ בימינו גיר ידני נמצא ברכבי ספורט או רכבים ישנים. ככל הנראה האמריקנים פחות נוטים להחזיק ברכבים אלו.
- דגמי יוקרה נדירים במכירתם מאחר ורוב הציבור אינו נוהג ברכבים מסוג זה.
- היצע הרכבים במדינה מספק מידע על רמת האמידות של תושביה. במדינות שנדיר למצוא בהן רכבים למכירה ניתן להסיק כי:
 - א. קיימת פלטפורמה אחרת לקנייה ומכירה.
 - ב. אין צורך ברכבים מאחר והתחבורה הציבורית מצויינת.
 - ג. אחזקת רכב עולה הרבה כסף. כמות רכבים לנפש במדינה עשויה להעיד על מצבם הכלכלי של התושבים.
 - ד. יש סנטימנט לאומי לציוד שעוברים בירושה ("וינטג", כמו בנאשוויל למשל).



במבט חטוף ניכר כי יש שני ערכים שניתן לאחד:



- AWD (All Wheel Drive) - מתייחס להנעה בכלל הגלגלים.
 - 4WD מתייחס להנעה בכל הגלגלים ברכבים בעלי 4 גלגלים.
- האמנם, במשאיות לפעמים ישנם 6 גלגלים שמעבירים את הכח מן המנוע אל האספלט, לכן 4WD מתייחס בד"כ לרכבים בעלי הנעה של 4 גלגלים, כלומר רכבים פרטיים שאינם משאיות בעלות הנעה מלאה, ו AWD למשאיות בעלות הנעה מלאה.
- מתוך היכרות עם הנושא ובחינת מס' שורות בודדות מן הדאטה סט, ניכר כי בונה מאגר המידע ערבב בין שני הסוגים, ולכן הם כבר אינם מספקים אינפורמציה בנפרד. לכן ניתן לאחד אותם.






את התפלגות המשתנים הקטגוריאליים אציג באמצעות bar – charts :














ניתן להציג את ההתפלגויות של המשתנים הקטגוריאליים ע"י דיאגרמה מסוג pie-chart :





סעיף 6 – קורלציה וקשרים

תת סעיף 1 – קטגוריות מספריות

הערה: מטריצת הקורלציה הינה סימטרית סביב האלכסון הראשי, לכן החצי התחתון המלא של המטריצה מספק את כלל המידע הדרוש על הקשרים בין המשתנים.

קורלציית פירסון

קורלציית פירסון מתארת קשר לינארי בין 2 משתנים:

(-1): קשר לינארי הפוך / שלילי. כאשר ערך משתנה אחד עולה, השני יורד בהתאם.

0: אין קשר לינארי.

1: קשר לינארי חיובי. כאשר משתנה אחד עולה גם השני.

	Year	Engine_Size	Mileage	Horsepower	Torque	Owners	Accident_History	Fuel_Efficiency	Selling_Price
Year	1.00								
Engine_Size	-0.06	1.00							
Mileage	-0.75	0.04	1.00						
Horsepower	0.05	0.67	-0.05	1.00					
Torque	0.06	0.57	-0.05	0.98	1.00				
Owners	-0.83	0.05	0.63	-0.05	-0.05	1.00			
Accident_History	-0.38	-0.00	0.30	-0.05	-0.04	0.32	1.00		
Fuel_Efficiency	0.16	-0.73	-0.13	-0.09	0.02	-0.15	-0.06	1.00	
Selling_Price	0.80	-0.03	-0.68	0.06	0.08	-0.67	-0.39	0.13	1.00

קורלציית ספירמן

קורלציית ספירמן מתארת קשר מונוטוני בין 2 משתנים (לא בהכרח לינארי):

(-1): קשר הפוך / שלילי. כאשר ערך משתנה אחד עולה, השני יורד.

0: אין קשר.

1: קשר חיובי. כאשר משתנה אחד עולה גם השני.

	Year	Engine_Size	Mileage	Horsepower	Torque	Owners	Accident_History	Fuel_Efficiency	Selling_Price
Year	1.00								
Engine_Size	-0.04	1.00							
Mileage	-0.78	0.03	1.00						
Horsepower	0.04	0.84	-0.03	1.00					
Torque	0.03	0.81	-0.02	0.97	1.00				
Owners	-0.84	0.03	0.67	-0.04	-0.03	1.00			
Accident_History	-0.38	0.00	0.34	-0.03	-0.02	0.33	1.00		
Fuel_Efficiency	0.10	-0.75	-0.08	-0.61	-0.57	-0.08	-0.04	1.00	
Selling_Price	0.88	0.02	-0.83	0.08	0.08	-0.76	-0.39	0.05	1.00



קורלציית קנדל

קורלציית קנדל (τ) מודדת את עוצמת הקשר המונוטוני בין המשתנים המספריים בדאטה על בסיס השוואת כל זוגות התצפיות האפשריים (כגון נפח מנוע, שנת ייצור ומחיר) ובדיקה אם הסדר היחסי ביניהן נשמר. בניגוד לקורלציית פירסון המניחה קשר ליניארי ורגישה מאוד לערכים חריגים, או קורלציית ספירמן המבוססת על דירוג סדרתי כללי, קנדל מתמקדת בספירת זוגות תואמים מול לא-תואמים. תכונה זו הופכת אותה לגישה שמרנית ועמידה יותר בפני ערכי קיצון, ולמדויקת במיוחד למאגרי נתונים שבהם קיימות חזרות מרובות על אותם ערכים מספריים (Ties). טווח ערכיה נע בטווח של $[-1, 1]$, כאשר 1 מייצג קשר מונוטוני חיובי מושלם (עלייה במשתנה אחד מלווה תמיד בעלייה בשני), -1 מייצג קשר מונוטוני שלילי מושלם, וערך הסמוך ל-0 מעיד על היעדר קשר סדרתי בין המשתנים.


הערה: מטריצת הקורלציה הינה סימטרית סביב האלכסון הראשי, לכן החצי התחתון המלא של המטריצה מספק את כלל המידע הדרוש על הקשרים בין המשתנים.

	Year	Engine_Size	Mileage	Horsepower	Torque	Owners	Accident_History	Fuel_Efficiency	Selling_Price
Year	1.00								
Engine_Size	-0.03	1.00							
Mileage	-0.62	0.02	1.00						
Horsepower	0.02	0.79	-0.02	1.00					
Torque	0.02	0.73	-0.02	0.87	1.00				
Owners	-0.71	0.02	0.52	-0.03	-0.02	1.00			
Accident_History	-0.32	0.00	0.28	-0.02	-0.01	0.30	1.00		
Fuel_Efficiency	0.07	-0.60	-0.06	-0.48	-0.45	-0.06	-0.03	1.00	
Selling_Price	0.71	0.01	-0.64	0.06	0.05	-0.61	-0.33	0.04	1.00



גרפי פיזור (scatterplot)

Scatter Plot Matrix for Numerical Variables





מסקנות מבוססות קורלציה

- אין קשר בין שנת ייצור הרכב לבין גודל המנוע. כלומר לא התחילו / הפסיקו לייצר רכבים בעלי גודל מנוע שונה בגלל תחילת שימוש ברכבים היברידיים / חשמליים או טרנדים אחרים בעולם ייצור הרכבים.
- ככל שהרכב על הכביש יותר זמן כמות הידיים שהוא עובר גדולה יותר, הוא צובר יותר קילומטראז' והסיכוי שלו לעשות תאונות גדל.
- קיים קשר הדוק בין גודל המנוע, כוח הסוס והמומנט.
- ככל שהמנוע והמומנט גדול יותר כך יעילות הדלק קטנה יותר משמעותית.
- המדדים המשפיעים ביותר על מחיר הרכב הינם: שנת הייצור, גודל המנוע, מרחק נסיעה, כמות בעלים קודמים וכמות התאונות.
- המדדים שאינם משפיעים על מחיר הרכב הם: ביצועיו ויעילות הדלק שלו.
- שנת הייצור אינה מעידה על יעילות הדלק. כלומר לא נעשה שיפור משמעותי במהלך השנים בנוגע לשיפור יעילות צריכת הדלק ע"י יצרני הרכבים.

השוני בין הקורלציות


- הקשר בין כ"ס ומומנט ליעילות דלק הינו מונוטוני שלילי – אך לא לינארי. זאת ניתן להסיק מהערך השלילי החזק של קורלציית ספירמן ומהערך הקרוב לאפס של קורלציית פירסון.



תת סעיף 2 – משתנים קטגוריאליים

Cramer's-V + Heatmap matrix

יצירת crosstab עבור כל קומבינציה של זוגות המשתנים הקטגוריאליים עשויה להעמיס על המסמך והמחברת ולגרום פספוס של תובנות מהותיות. כדי לבחון את עוצמת הקשר בין 9 המשתנים הקטגוריאליים, חושבה מטריצת V-Cramer's לכל 36 הקומבינציות האפשריות. מטריצה זו מייצגת את חוזקת הקשר בין כל זוג משתנים קטגוריאליים. להלן מטריצת הסיכום, ולאחריה ניתוח מפורט באמצעות טבלאות שכיחות מוצלבות (Crosstab) עבור הקשרים הבולטים ביותר שנמצאו בדאטה.



ע"פ מטריצת זו ניתן לקבוע כי :

- הדגם נותן מידע וודאי על היצרן.
- הדגם נותן מידע וודאי על סוג גוף הרכב.
- סוג הנעת הרכב נותנת חיווי משמעותי על סוג הגוף, המודל והיצרן.
- סוג הגוף נותן חיווי על היצרן.

כעת לאחר שהבנו מהם המשתנים הקטגוריאליים הקשורים ביותר נוכל לייצר מטריצות crosstab עבור כל זוג.



Crosstab matrix

מאחר וקיימים מספר רב של ערכים אפשריים לכל משתנה קטגוריאלי מטריצות אלו נמצאות במחברת. צפייה בהן במחברת מאפשרת אבחנה מדוקדקת שלהן מאשר בוורד – פלטפורמה שאינה מתאימה להצגת טבלאות גדולות.



מציאת קשר בין משתנים קטגוריאליים למספריים

מדד Cramer's V וטבלאות שכיחות מוצלבות (Crosstabs) מיועדים למדידת תלות בין משתנים קטגוריאליים בלבד. מכיוון שמשתנים כמו מחיר, כוח סוס או נפח מנוע הם רציפים ומכילים ערכים מספריים רבים, אי-אפשר לחשב עבורם טבלת הצלבה קריאה. הבינינג המיר את המשתנים המספריים לקטגוריות סדורות (Low, Medium, High) ובכך מאפשר לנתח את עוצמת הזיקה הסטטיסטית בינם לבין הקטגוריות המקוריות.

חלוקה לפי Quantiles : הנתונים של כל משתנה מספרי חולקו ל-3 קבוצות גודל שוות בקירוב (כ-33% מהתצפיות בכל קבוצה).

מסקנות מרכזיות מתוצאות הניתוח

1. קשרים חזקים (גודלים מ 0.3) :

- Model ו-Body_Type מול מפרט המנוע : נמצאה תלות חזקה מאוד (0.376 – 0.396) מול נפח מנוע (Engine_Size), כוח סוס (Horsepower), מומנט (Torque) וצריכת דלק (Fuel_Efficiency).

- משמעות : המהות הפיזית וההנדסית של הרכב קובעת באופן ישיר את ביצועי המנוע (למשל : סוג מרכב SUV או דגם ספורטיבי משויכים מראש למנועים חזקים בעלי מומנט גבוה).

2. קשרים בינוניים ($0.20 < \text{Cramer's } V < 0.30$) — מגמות שוק ותמחור :

- תיבת הילוכים (Transmission) מול שנת ייצור (0.285) ומחיר (0.216) : מעיד על שינוי טכנולוגי לאורך השנים (מעבר לגירים אוטומטיים/רציפים בשנים מתקדמות) ועל השפעת סוג הגיר על תמחור השוק.
- סוג הנעה (Drivetrain) מול נפח ומפרט (0.256 – 0.269) : רכבי הנעה כפולה (AWD/4WD) מגיעים לרוב עם מנועים גדולים וחזקים יותר.
- מחיר מכירה (Selling_Price) : מושפע בעיקר מהדגם (0.240), סוג הגיר (0.216) והיצרן (0.204).

3. משתנים בלתי-תלויים ($\text{Cramer's } V < 0.10$) — רעש ללא השפעה :

- Location, Color ו-Service_History : הראו ערכי קרמר זניחים ($V < 0.10$) מול כל המשתנים המספריים.
- משמעות : צבע הרכב, מיקומו הגיאוגרפי או היסטוריית הטיפול אינם משפיעים ואינם קשורים באופן שיטתי למחיר, לשנת הייצור, לביצועי המנוע או לקילומטראז' בדאטה. ניתן להשמיט משתנים אלו מאימון מודלים לניבוי ביצועים או מחיר.




סעיף 7 – ניתוח האינדקס

ציר הזמן – במאגר מידע זה אין חשיבות לציר הזמן.

השתנות הערכים כתלות בזמן

בחנתי את הפרמטרים הטכניים (הנומריים) הרלוונטיים בלבד ובעלי פוט' שינוי לאורך השנים ע"מ לקבל מסקנות בנוגע למגמות בייצור הרכבים – האם הם מייצרים רכבים יעילים יותר מבחינת דלק, בעלי גודל מנוע גדול יותר וכו'.

כפי שניתן לראות הפרמטר בעל השינוי הכי משמעותי לאורך השנים הוא היעילות בדלק. את השינוי ניתן לייחס לחדירת השוק של רכבים חשמליים והיברידיים שצורכים חשמל במקום דלק.



מיון הנתונים

המידע אינו ממויין.



סעיף 8 – תובנות וסיפור הנתונים

- 3 תובנות מרכזיות :
 1. המפרט ההנדסי של הרכב מוכתב ע"י הקטגוריה : דגם וסוג הרכב מכתיבים את נפח המנוע, כ"ס והמומנט. תובנה זו הגיונית מאחר והיא מבטאת את הצורך בפרמטרים גבוהים יותר ע"מ להניע רכב גדול יותר.
 2. הפרמטרים המשמעותיים ביותר לקביעת מחיר רכב הם :
 - א. שנת ייצור
 - ב. מרחק נסיעה
 - ג. כמות בעלים
 3. זיהוי משתני רעש : צבע, מיקום גיאוגרפי והסטוריית טיפולים הראו אי תלות סטטיסטית כמעט מלאה מול כלל שאר המשתנים.
- לפחות הטיה אחת או סיכון :
 - א. לא ידוע אם הדאטה מייצג את כלל שוק מכירת הרכבים, לכן לא ניתן להסיק ממנו מידע על קטגוריות שוליים – כמו רכבי אספנות, יוקרה וכו'.
 - ב. קיים סיכון להטיית סלקטיביות ולדיווח שקר.
 - ג. ערכים רבים מתוך הדאטה מלאים בפרמטר "לא ידוע", דבר שמקשה על הסקת מסקנות חד משמעית.
- נק' כשל או אפשרויות לשימושים הנדסיים סטטיסטיים :
 1. שימוש הנדסי-סטטיסטי : ביצוע סינון תכונות להשמטת משתני רעש (צבע, מיקום), כצעד מקדים לאימון מודל למידת מכונה לניבוי מחירי רכב.
 2. איסוף נתונים לא מקצועי של אוסף המידע, תיוג לא נכון והטיות סלקטיביות עשויות להוות סיכון בעת אימון מודל סטטיסטי לחיזוי פרמטרים.
- מה למדתי בניתוח :
 1. למדתי לגשר על הפער בין משתנים רציפים לקטגוריאליים באמצעות Binning ומטריצת Cramer's V.
 2. למדתי להיזהר מאינטרפרטציה מוטעית של ציר הזמן, ולהבחין בין מגמות טכנולוגיות (שיפור ביעילות דלק) לבין פחת בנתוני חתך.
- האם דעתי השתנה על התחום?

התפיסה שלי השתנתה מהסתכלות על מסד נתונים כטבלת מחירים מסחרית בלבד, להבנה שהוא מייצג מערכת הנדסית מורכבת שבה חוקים פיזיקליים (גודל מנוע ומומנט) והרגלי צריכה חברתיים שלובים זה בזה ומכתיבים את ערך השוק.



סעיף 9 – בונוס

- תלות בזמן. האם יש קשר למידע חיצוני שאנחנו יודעים על הזמן?
 1. מגמות של שימוש עולה ברכבים היברידיים וחשמליים ככל שציר הזמן מתקדם עוזר לנו בהבנת המגמות המשתקפות מהדאטה.
 2. ניכר כי רוב הפרמטרים ההנדסיים נשארו קבועים באופן רוחבי עבור כלל הרכבים המוצעים למכירה (מכלל השנים).
- Engineering feature
 1. בעת אימון מודל סטטיסטי יש לציין אך ורק את המשתנים בעלי הקורלציה ע"מ לא להוסיף רעש למערכת.
- בדיקת השערות

המגמות שנמצאו לא הפתיעו אותי. מאחר ואני בקיא בעולם זה אני גם יודע להסביר חלק מן התופעות:

 1. באופן לא מפתיע הפרמטרים המספריים (שנה, קילומטראז') הם הגורמים המהותיים בקביעת מחיר הרכב.
 2. פרמטרים אלו המשמעותיים ביותר בגלל חוסר ההבנה של הצרכנים בהגדרת תקינות הרכב:
 - א. שגרת טיפולי הרכב.
 - ב. קיום טיפולים והחלפות כלל החלקים ע"פ ספר רכב
 - ג. צריכת הדלק של הרכב – פרמטר שמעיד על הכלכליות של אחזקת רכב.
 3. צבע ומיקום מוסיפים רעש למערכת ואינם מהווים שיקול אמיתי בקביעת המחיר.
- הצעות למחקר נוסף
 1. חיזוי מחיר רכב על סמך כלל הפרמטרים. יכול להיות שימושי עבור חברות שמאות בארה"ב.
 2. הסקת מסקנות על הרגלי צרכנות הרכב בפילוח ע"פ מדינות. יכול להיות שימושי עבור יצרני הרכב.



דגשי למידה

מה נמדד

- 1. מאפייני מודעות רכב יד-שנייה : נתונים טכניים, מסחריים והיסטוריים של 5,500 רכבים מלוחות מכירה בארה"ב. מפרט הנדסי וביצועים : נפח מנוע, כוח סוס, מומנט, צריכת דלק, סוג הנעה ותמסורת.
- 2. היסטוריית שימוש ומצב : שנת ייצור, קילומטראז', כמות בעלים קודמים, היסטוריית תאונות והיסטוריית טיפולים.
- 3. נתונים מסחריים וגיאוגרפיים : מחיר מבוקש למכירה, יצרן, דגם, סוג מרכב, צבע ומיקום בתוך ארה"ב.

מה חסר

- 1. מחיר עסקה סופי : הנתון במאגר מייצג את מחיר הדרישה במודעה ולא את מחיר הסגירה בפועל לאחר מיקוח ובדיקה.
- 2. מחיר מקורי כחדש (MSRP) : היעדר נתון המחיר המקורי של הרכב ביום יציאתו מהמפעל מונע חישוב מדויק של אחוז ירידת הערך (Depreciation Rate) הריאלי.
- 3. ציר זמן עוקב (Longitudinal Data) : הנתונים הם נתוני חתך (Cross-sectional) ברגע בודד, ללא מעקב לאורך השנים אחרי אותן שילדות (ללא מזהה רכב).
- 4. ערכים חסרים בטבלה : כ-14%-15% חוסרים (כ-800 רשומות) בשדות מפתח כגון מומנט, כוח סוס, היסטוריית טיפולים ומיקום עקב כשל באיסוף הנתונים.
- 5. מדדים ייעודיים לרכבים חשמליים : חסרים מדדים טכנולוגיים רלוונטיים כמו קיבולת סוללה (kWh), טווח נסיעה ובריאות הסוללה.

מה מוטא

- 1. הטיית הישרדות : המדגם כולל רק רכבים ישנים ששרדו ונמצאים במצב נסיעה/מכירה, בעוד רכבים קלוקלים מאותן שנים כבר ירדו מהכביש.
- 2. הטיית דיווח וסלקטיביות : מוכרים נוטים להשמיט מידע שלילי או לדווח בצורה חלקית/סובייקטיבית בשדות כמו היסטוריית תאונות וטיפולים.
- 3. הטיית איסוף (Scraping Bias) : הנתונים נאספו מלוח מכירות מסוים באופן לא מבוקר על ידי גורם פרטי, ולכן אינם מייצגים באופן מבוקר את שוק הרכב העולמי.

מה ממורכז באופן מלאכותי

- 1. דיסקרטיזציה : בעת השוואת ערכים נומריים וקטגוריאליים חלוקת הנתונים הרציפים ל-33% בכל קבוצה באופן מלאכותי מעלימה התפלגויות טבעיות וזנבות.
- 2. ערכי place holders כמו גודל מנוע לרכב חשמלי : קביעת ערך 0 באופן מלאכותי בעמודת נפח המנוע עבור רכבים חשמליים על ידי מזין הנתונים משנה את כלל הערכים הסטטיסטיים
- 3. השלמת קטגוריות חסרות : קיבוץ ערכים חסרים תחת קטגוריה מלאכותית בשם 'NaN'.